

基于深度学习的核电厂事故诊断 技术

成 员：齐奔¹ 王彧¹ 陆林²

院 系：1 核研院 2 医学院

日 期：2023 年 1 月 7 日

摘要

核能在全球能源供应中发挥着重要作用，尤其是作为一种关键的低碳电力来源。然而，保证核电厂的安全运行是至关重要的。鉴于人因失误对历史上三起严重核事故的重大影响，人工智能（AI）已被越来越多地用于协助操作员做出各种决策。特别是，数据驱动的人工智能算法适用于处理核电厂庞大的监测信息，借助人工智能技术可以更好地帮助操作员诊断事故状态。另一方面，尚缺乏一个公开的核电厂事故数据集来衡量各种算法的性能。因此，本项目选取核电厂的典型代表-核电厂作为研究对象，基于核电厂仿真机-PCTTRAN 构建一个核电厂事故数据集，并探索了虚假数据集生成技术和核电厂事故诊断技术，对两种技术中涉及的各项模型进行了对比分析。实验结果表明，在生成虚假数据集方面，TimeGAN 相较于 cGAN 表现出更高的性能，TimeGAN 可以更好的捕捉时序数据的动态特征。在事故诊断方面，我们基于 MLP、CNN、RNN、Transformer 四类模型对事故类别进行分类，在真实数据上进行实验，结果表明 Transformer 对事故有最好的分类能力。另外，数据的标准化对分类效果有较大影响，在数据预处理时进行标准化处理，会使得所有模型的效果都大幅度提高。

目录

摘 要	2
1. 项目背景	5
2. 数据集构建	6
2.1 PCTRAN 软件	6
2.2 数据集构建	6
2.2.1 仿真流程	6
2.2.2 数据预处理	7
3. 虚假数据生成技术	8
3.1 条件生成对抗网络(cGAN)	9
3.2 时间序列对抗生成网络 TimeGAN	9
3.3 结果分析	10
4. 核电厂事故诊断技术	12
4.1 多层感知机 (MLP)	13
4.1.1 模型超参数设置	13
4.1.2 模型结构	13
4.1.3 模型参数量统计	14
4.1.4 Loss 曲线	14
4.1.5 混淆矩阵	15
4.2 卷积神经网络 (CNN)	15
4.2.1 模型超参数设置	15
4.2.2 模型结构	16
4.2.3 模型参数量统计	17
4.2.4 Loss 曲线	18
4.2.5 混淆矩阵	19
4.3 循环神经网络 (RNN)	19
4.3.1 模型超参数设置	19
4.3.2 模型结构	20
4.3.3 模型参数量统计	21
4.3.4 Loss 曲线	21
4.3.5 混淆矩阵	22
4.4. Transformer 网络	22
4.4.1 模型超参数设置	22
4.4.2 模型结构	23
4.4.3 模型参数量统计	23
4.4.4 Loss 曲线	24

4.4.5 混淆矩阵	24
4.5 模型对比	25
4.5.1 模型超参数设置	25
4.5.2 模型信息和结果	25
4.5.3 分析与讨论	27
5.项目总结	28
5.1 结论	28
5.2 展望	28
参考文献	29

1. 项目背景

核能自诞生之日起，就伴随着巨大争议。支持者推崇核能的安全、清洁和高效，反对者介怀历史上三次核事故，谈“核”色变。从 1951 年第一个生产电力的核反应堆在美国诞生，到 1954 年苏联建设的第一个核电站，再到二十世纪六七十年代开发和建造的众多商业核反应堆，许多人认为核电有希望成为未来的电源。1974 年法国大力推动核能的发展，最终通过核反应堆产生了高达 75% 的电力，在同一时期美国大约 20% 的能源生产来自核能。然而，三里岛核事故、切尔诺贝利核事故和福岛核事故的发生，使核电的未来受到了质疑，全球能源发展焦点开始从核能转移开，但是今天全球约 10% 的能源仍然是通过核电站生产的。根据美国哥伦比亚大学气象学家詹姆斯·汉森（James Hansen）的分析，通过抵消使用化石燃料造成的空气污染，核能在其历史上可能已经拯救了 180 万条生命。我们同样应当看到，这些灾难的发生也促进更安全的反应堆设计的产生。如我国的华能石岛湾高温气冷堆，它的固有安全特性大大降低了严重事故发生的可能性。除此之外，核事故是不可能被消除的，任何新的系统设计或措施都只能降低事故发生的概率，必须充分做好场内和场外应急准备。原子能机构总干事天野之弥在报告《福岛第一核电站事故》也明确提出，核事故后应提供强有力的手段来监测严重事故中的反应堆和乏燃料安全参数以及确保场外应急监测和应急控制中心能够在严重工况下有效工作{福岛第一核电站事故}。福岛核事故经验警示我们，为避免核事故严重后果，必须在应急响应能力上有实质性、大幅度改进和提升。

当前核事故应急一般包括以下四个关键技术环节：（1）事故（机组）状态诊断；（2）事故源项估计；（3）事故后果评价；（4）防护行动建议与实施。其中，事故状态诊断是通过对核电厂运行状态的实时监测，为操作人员提供核电厂可能发生的事故的判断，并分析事故原因；事故源项估计是指核反应堆在事故后通过安全壳或者旁路向大气中释放的反射性物质的释放量；事故后果评价是指通过建模确定放射性物质对人体和环境的危害；防护行动建议与实施是指基于事故后果评价结果，做出合理的防护行动建议。

事故状态诊断是整个核应急过程中的首要环节，对于保证核应急正确执行有着重要意义。事故状态诊断技术可分为基于传统方法和基于人工智能的两种类型。前者在实际电厂中有着广泛的应用，后者属于新兴的研究热点。这些传统方法都需要人为去判断，对人的依赖性较高。历史上爆发的三次核事故中人为因素是事故发生的主要原因之一，这些事故教训警示着我们有必要发展可替代人去判断当前事故工况的先进技术。除此之外，核电厂有数百个子系统以及大量的监视和控制参数，虽然操作员经过相应的培训，但是当事故发生时，巨大的心理压力易使他们产生误判，可能导致严重的放射性后果。因此，仅依靠操纵员去处理这些庞大的信息具备较高风险。随着人工智能的兴起，学者们开始研究基于人工智能的核事故诊断技术。相比人类，人工智能在以下几个方面具备显著优势：（1）信息处理效率，借助人工智能可在短期内处理核电厂各类信息源，帮助人们在事故发生后快速提取到关键信息，从而采取正确的行动；（2）消除人为错误，即使是核领域最顶尖的专家也存在出错的可能，而基于

特定任务搭建的人工智能系统不会出现这种失误；(3)持续工作能力，理论上人工智能机器可以一直保持工作状态，对于核电厂来说，持续的事故状态监控是必要的。因此，将人工智能技术引入到核电厂事故诊断上，是一项值得探索的工作。

利用深度学习课程知识，并结合核电厂事故诊断技术现状，本项目以当前较为先进的第三代压水堆“华龙一号”核电厂为研究对象，构建了一个涵盖主要事故类型的核电厂数据集，并基于数据集开展了虚假数据生成技术和事故诊断技术研究。

2. 数据集构建

2.1 PCTRAN 软件

PCTRAN 是基于 PC 的多反应堆堆型核能仿真软件包，可以对堆芯熔化，安全壳失效和放射性物质释放等严重事故进行虚拟仿真，并提供了如图 1 所示的仪表和控制显示。

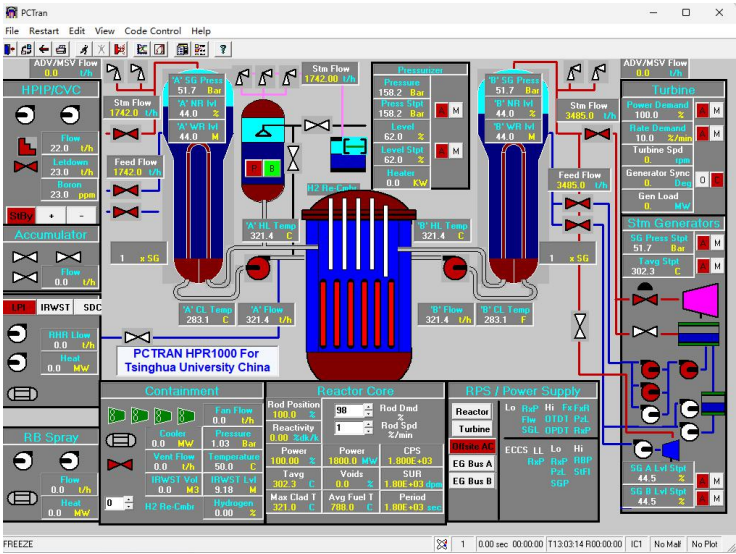


图 1 PCTRAN 软件界面

2.2 数据集采集

2.2.1 仿真流程

数据集^[1]生成流程如图 2 所示,通常情况下,仿真每个事故需要进行手动按键/鼠标操作，

如初始化运行条件、选择事故类型、设置事故参数和结束事故模拟。具体来说，每个事故都是在核电站全功率运行的 20s 时刻插入的，数据采样的时间步长为 10s，每个事故的平均模拟时间为~4000s。当处理大量的事故样本时，复杂的手工操作将变得非常低效。在这项工作中，开发了程序脚本来实现流程自动化。

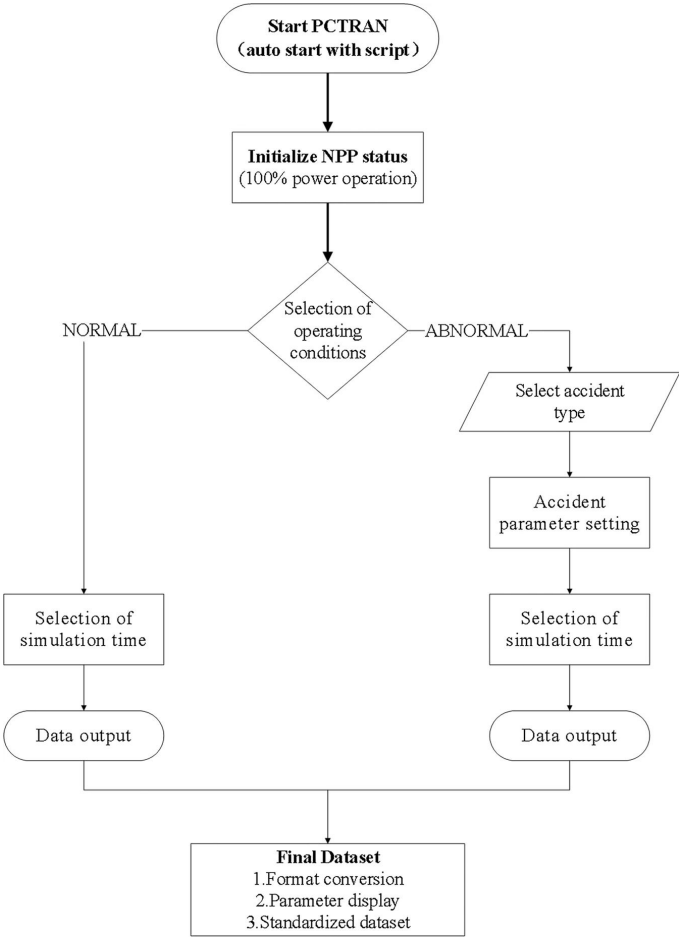


图 2 仿真数据集生产流程

2.2.2 数据预处理

原始数据集样本组成如表 1 所示，属于平衡分布数据集，事故特征参数为 96 个。截取事故发生后 960s 的数据（采样间隔 10s），得到维度为[96, 96]的归一化样本。特征间数量级差异较大，采用最大值归一化处理。

表 1 数据集结构

Accident	Description	Number	Severity
LOCA	Loss of Coolant Accident (Hot Leg)	100	% of 100 cm ²
LOCAC	Loss of Coolant Accident (Cold	100	% of 100 cm ²

	Leg)		
SLBIC	Steam Line Break Inside Containment	101	% of 100 cm ²
SLBOC	Steam Line Break Outside Containment	100	% of 100 cm ²
SGATR	Steam Generator A Tube Rupture	100	% of 1 full tube rupture
SGBTR	Steam Generator B Tube Rupture	110	% of 1 full tube rupture
RW	Rod Withdrawal	100	% (+/-) withdrawn
RI	Rod Insertion	82	% (+/-) insertion
FLB	Feedwater Line Break	100	% of 100 cm ²
MD	Moderator Dilution	100	% of unborated injection
LR	Load Rejection	99	% of full load rejected
LLB	Letdown Line Break in auxiliary buildings	101	% of nominal letdown flow

3. 虚假数据生成技术

由于核电厂具有极高的安全性和可靠性，从商用核电厂诞生至今发生了极少的核事故，目前只能利用仿真数据构造有限大小的数据集。而 GAN 作为一种生成模型，具有虚假数据生成能力，我们希望借助 GAN 模型生成更多的数据，来增强原始数据集。因此，这部分探索了基于 CGAN 和 TimeGAN 模型生成核电厂事故数据的可能性。

3.1 条件生成对抗网络(cGAN)

原始 GAN 不能按照指定标签生成数据，Mehdi Mirza 等人提出了 cGAN^[2]（图 3），其核心在于将标签信息 y 融入生成器 G 和判别器 D 中。利用 cGAN 可以按照事故标签生成相应的事故数据。

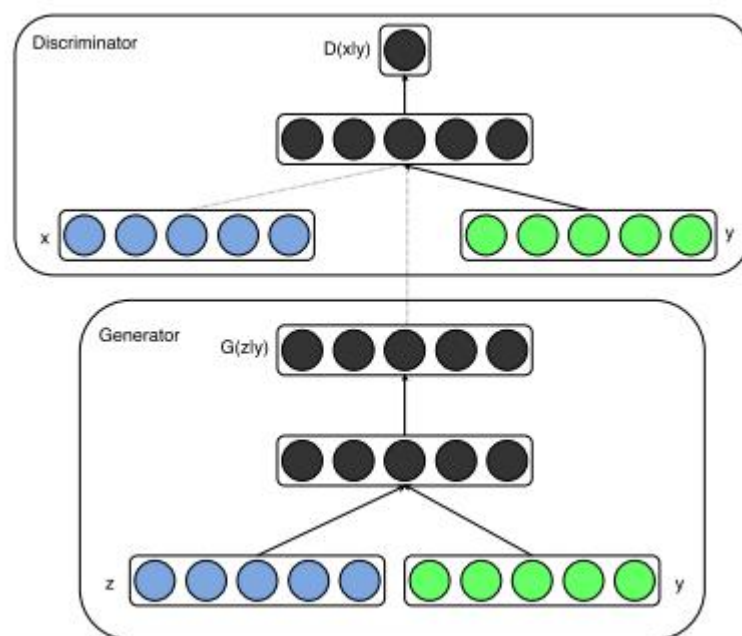


图 3 条件生成对抗网络

3.2 时间序列对抗生成网络（TimeGAN）

TimeGAN^[3] (Time-series Generative Adversarial Network) 是一种时间序列数据生成模型，由加州大学 Jinsung Yoon 等人在 NeurIPS 2019 中提出。主要思路是将无监督 GAN 方法的多功能性与有监督的自回归模型提供的条件概率原理结合，来生成保留时间动态的时间序列。如图 4 所示，TimeGAN 由四个网络组件组成：嵌入功能，恢复功能，序列生成器和序列判别器。

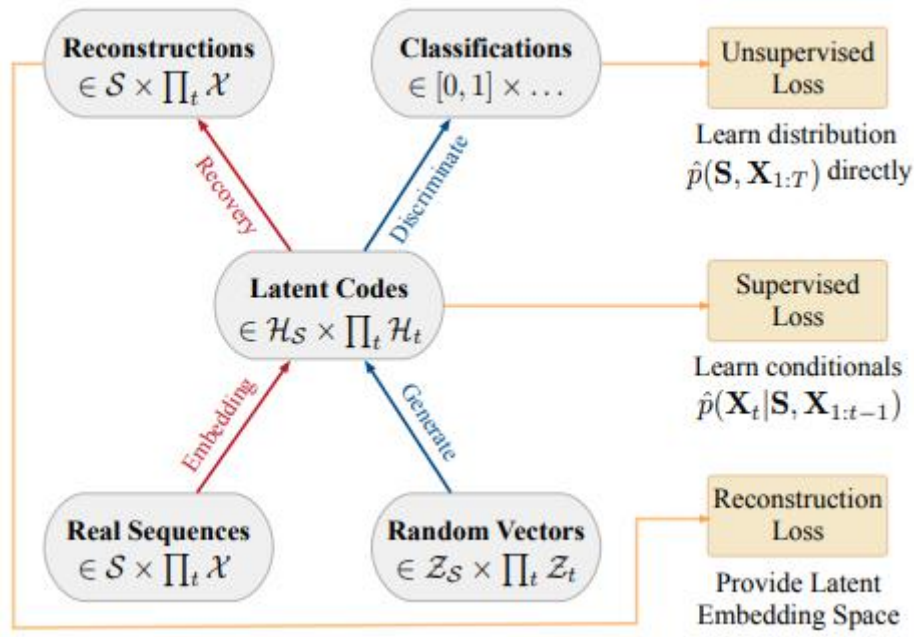


图 4 时间序列生成对抗网络


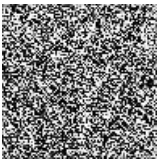
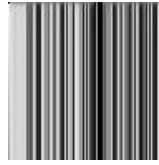
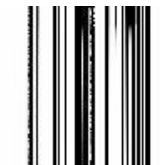
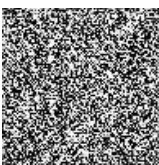
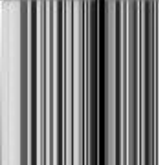









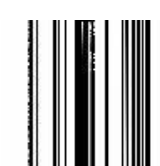








3.3 结果分析

通过以下两项判别准则。比较两种模型的性能：

- (1) 保真度：由于时序数据具有鲜明的物理特征，受视觉领域图像生成思想启发，将生成数据和真实数据转为图像，通过观察图像效果和 FID 值计算，来比较两种模型的性能。
- (2) 事故诊断得分：用生成数据训练核电厂事故诊断模型，在真实数据集上测试，用真实数据测试集的准确率作为得分。

保真度比较如表 2 所示，通过比较图像效果和 FID 值，TimeGAN 生成数据的质量显著高于 cGAN。事故诊断得分如表 3 所示，按照与真实数据集 1: 1 比例，使用两种模型分别生成数据集。构建了表 3 中所示的四种数据集，其中两个混合数据集为 80% 真实数据集和生成数据集组成。四种数据集采用同一个测试集（10% 真实数据集），准确率越高则证明模型生成数据质量越高，总体上，生成数据所训练的模型性能都比较一般，这是由于真实数据集样本量较少，使得模型欠拟合。单独比较两种模型性能，TimeGAN 准确率大部分情况下都高于 cGAN, 显然是因为 TimeGAN 能更好的捕捉时序数据集的时序动态特征。

表 2 保真度比较

标签	真实数据	生成数据 (cGAN)	生成数据 (TimeGAN)	FID (cGAN)	FID (TimeGAN)
FLB				549.2	302.2
LLB				510.1	318
LOCA				498.5	191.2
LOCAC				489.4	174.3
LR				602.7	377.5
MD				509.0	310.2
RI				525.8	233.9
RW				545.6	284.8


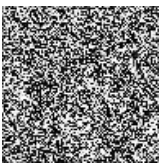


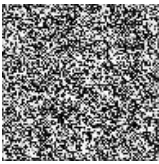


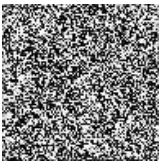


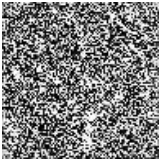
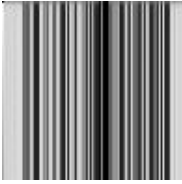
SGATR				521.5	332.9
SGBTR				514.9	305.0
SLBIC				531.2	282.1
SLBOC				467.0	250.7

表 3 事故诊断得分

模型	生成数据集 (cGAN)	生成数据集 (TimeGAN)	混合数据集 (原始+cGAN)	混合数据集 (原始+TimeGAN)
MLP1	19.33%	6.72%	94.12%	97.48%
MLP2	5.04%	5.88%	93.28%	96.64%
Resnet	10.92%	19.33%	100%	99.16%
DenseNet	10.92%	4.20%	99.16%	99.16%
GRU	0.84%	26.05%	86.55%	92.44%
LSTM	0.84%	17.65%	89.92%	93.2%
Transformer	5.88%	13.45%	99.16%	99.16%

4.核电厂事故诊断技术

我们探索了深度学习中常见的判别模型—多层感知机（MLP）、卷积神经网络（CNN）、循环神经网络（RNN）和 Transformer 等模型在核电厂事故诊断方面的性能。

4.1 多层感知机（MLP）

4.1.1 模型超参数设置

表 4 MLP 超参数设置

超参数	数值
初始学习率 lr	0.0001
迭代次数 nepoches	250
动量 momentum	0.9
批次大小 batch_size	32
随机失活 dropout	0

MLP 模型统一的超参数设置如上表所述，优化器采用随机梯度下降（Stochastic Gradient Descent, SGD）。

4.1.2 模型结构

MLP 选取了四种模型：一层全连接层和带首层 BN 层的一层全连接层，四层全连接层和带首层 BN 层的四层全连接层的 MLP 网络，四种模型都接上 softmax 激活函数做分类器。

表 5 MLP 模型结构

模型名称	模型结构	详细信息
MLP1	fc1	(9216, 12)
	softmax	—
MLP1(with first BN layer)	bn1, fc1, relu1	(9216, 12)
	softmax	—
MLP4	fc1, relu1	(9216, 512)
	bn2, fc2, relu2	(512, 256)
	bn3, fc3, relu3	(256, 64)
	bn4, fc4	(64, 12)
	softmax	—
MLP4(with first BN layer)	bn1, fc1, relu1	(9216, 512)
	bn2, fc2, relu2	(512, 256)
	bn3, fc3, relu3	(256, 64)
	bn4, fc4, relu4	(64, 12)

	softmax	—
--	---------	---

4.1.3 模型参数量统计

表 6 参数量统计

模型名称	FLOPS	Params
MLP1	3.54M	0.11M
MLP4	155.84M	4.87M

一层全连接层和四层全连接层的 MLP 网络浮点计算次数和参数量如上所示。

4.1.4 Loss 曲线

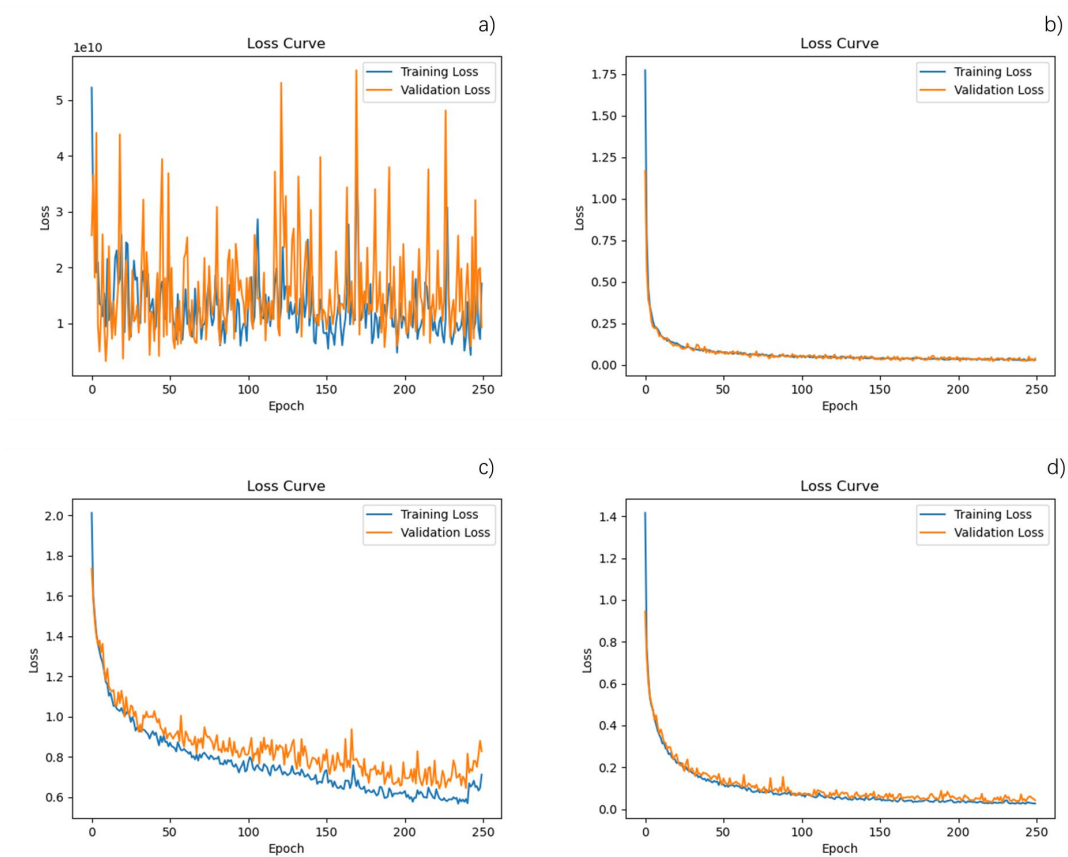


图 5 MLP 训练过程中训练和验证的 Loss 曲线 a)MLP1 b)MLP1(BN) c)MLP4 d)MLP4(BN)

一层全连接层和带首层 BN 层的一层全连接层，四层全连接层和带首层 BN 层的四层全连接层的 MLP 网络的真实测试集准确率分别为 9.24%、99.16%、62.18%和 99.16%。训

练的训练与验证的 Loss 曲线如上所述。

4.1.5 混淆矩阵

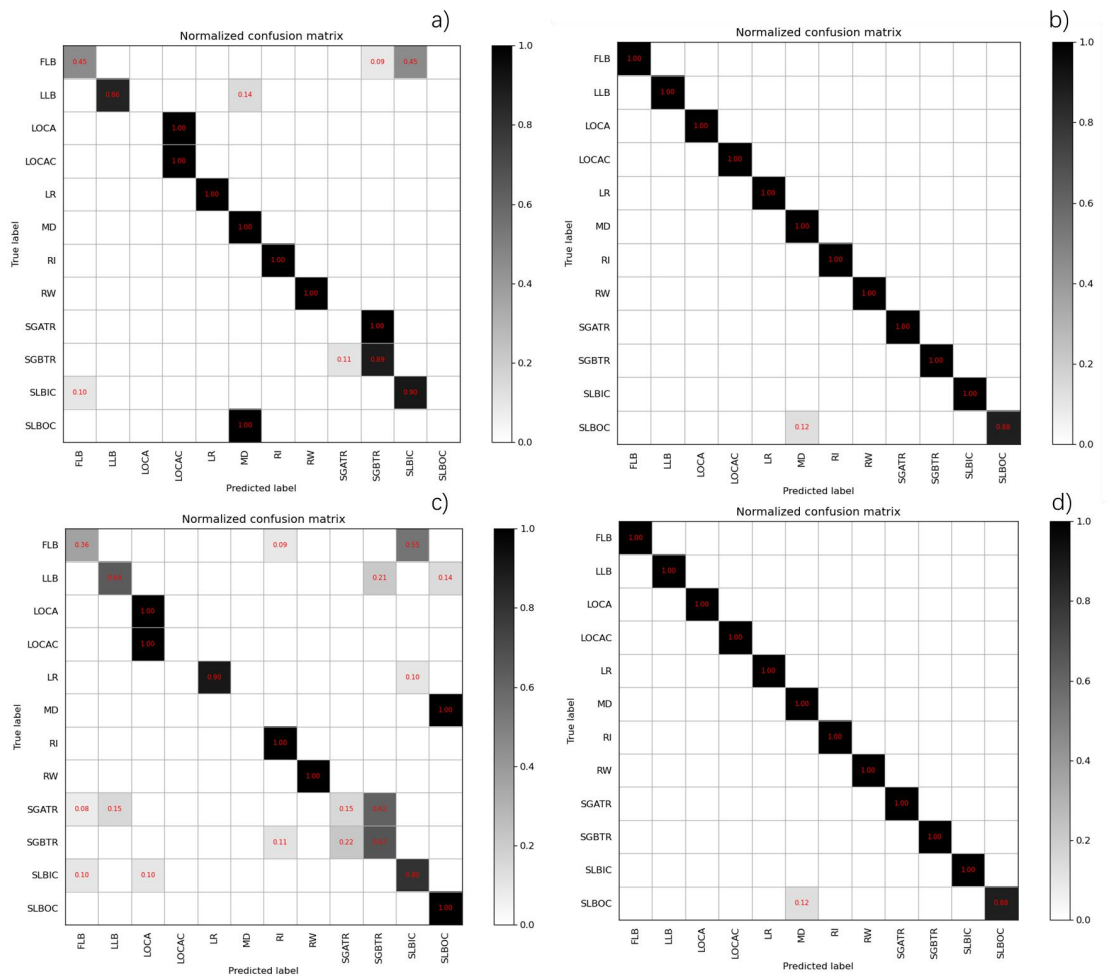


图 6 MLP 网络最佳模型的混淆矩阵 a)MLP1 b)MLP1(BN) c)MLP4 d)MLP4(BN)

一层全连接层和带首层 BN 层的一层全连接层，四层全连接层和带首层 BN 层的四层全连接层的 MLP 网络的混淆矩阵如上所述，与真实测试集准确率相对应。

4.2 卷积神经网络（CNN）

4.2.1 模型超参数设置

表 7 CNN 超参数设置

超参数	数值
-----	----

初始学习率 lr	0.001
迭代次数 nepoches	250
动量 momentum	0.9
批次大小 batch_size	32
随机失活 dropout	0

训练时优化器采用 SGD，参数如上表中所示。

4.2.2 模型结构

模型主要采用了浅层的 ResNet 和 DenseNet，ResNet_3 表示使用了 3 层 ResNet BasicBlock，DenseNet_4 表示使用了 4 层 DenseBlock。

表 8 CNN 模型结构

模型名称	模型结构	详细信息
ResNet_3	1*1 conv	(3*96*96)
	7*7 conv	(64*48*48)
	Basic Block1	(128*24*24)
	Basic Block2	(64*12*12)
	Basic Block3	(32*4*4)
	FC	(512, 12)
	softmax	—
ResNet_3 (with first BN layer)	BN_2d	(1*96*96)
	1*1 conv	(3*96*96)
	7*7 conv	(64*48*48)
	Basic Block1	(128*24*24)
	Basic Block2	(64*12*12)
	Basic Block3	(32*4*4)
	FC	(12)
	softmax	—
DenseNet_4	7*7 conv	(64*48*48)
	Dense Block1	(48*24*24)
	Dense Block2	(40*12*12)
	Dense Block3	(36*6*6)
	Dense Block4	(68*3*3)
	Averaged Pooling	(68)

	FC	(68, 12)
	softmax	—
DenseNet_4 (with first BN layer)	BN_2d	(1*96*96)
	7*7 conv	(64*48*48)
	Dense Block1	(48*24*24)
	Dense Block2	(40*12*12)
	Dense Block3	(36*6*6)
	Dense Block4	(68*3*3)
	Averaged Pooling	(68)
	FC	(68, 12)
	softmax	—

4.2.3 模型参数量统计

表 9 CNN 参数量统计

模型名称	FLOPS	Params
ResNet_3	12187.01M	0.50M
DenseNet_4	1469.34M	0.19M

4.2.4 Loss 曲线

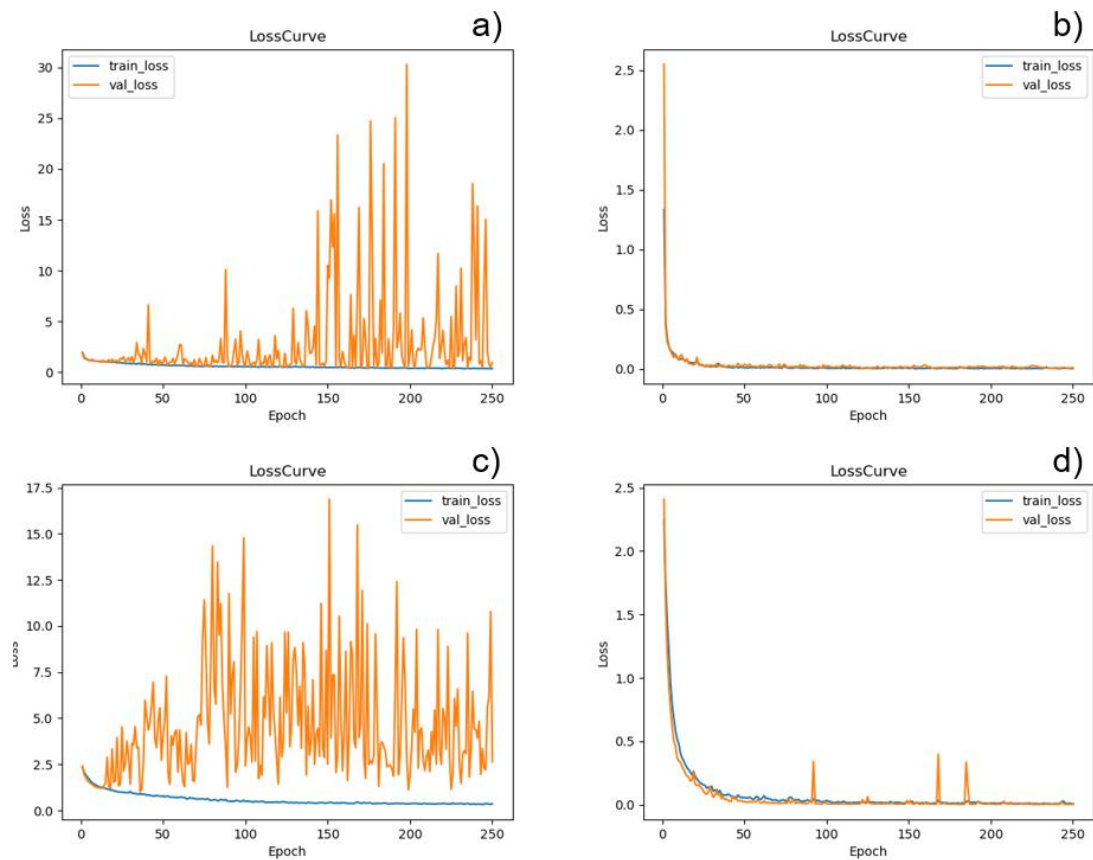


图 7 CNN 训练过程中训练和验证的 Loss 曲线。a)ResNet b)ResNet with BN c)DenseNet d)DenseNet with BN

ResNet、带首层 BN 层的 ResNet、DenseNet 和带首层 BN 层的 DenseNet 在真实数据测试集上的准确率分别为 67.23%，99.16%,38.66%,99.16%

4.2.5 混淆矩阵

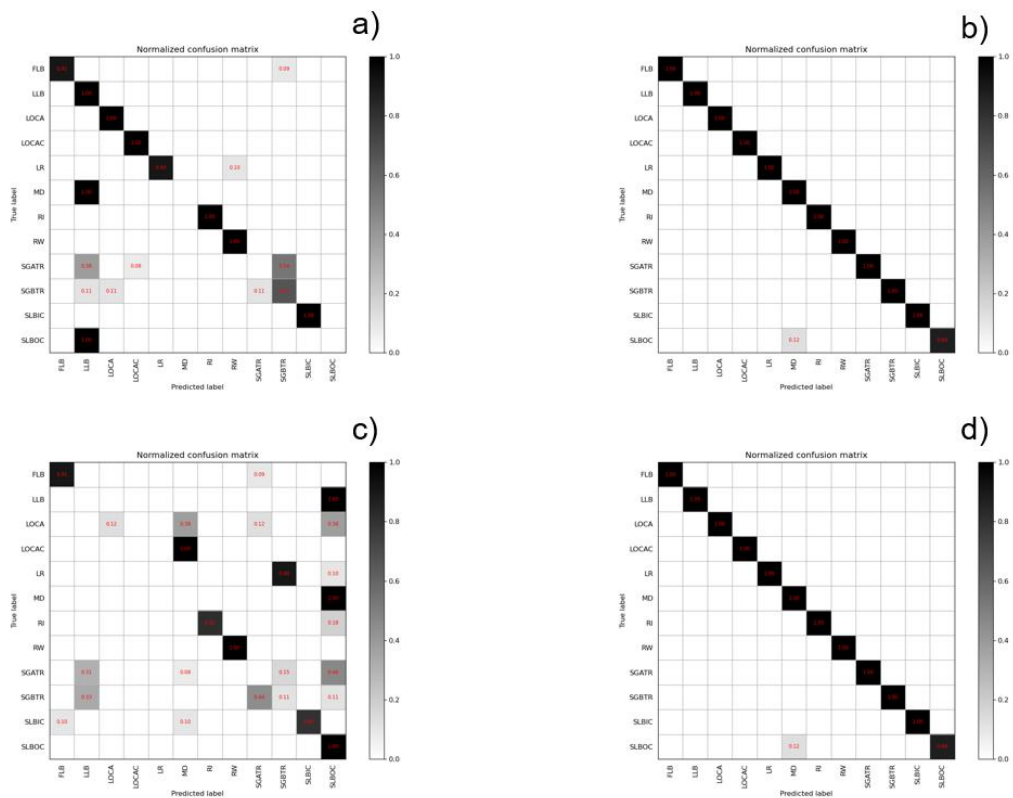


图 8 混淆矩阵 a)ResNet b)ResNet with BN c)DenseNet d)DenseNet with BN

ResNet、带首层 BN 层的 ResNet、DenseNet 和带首层 BN 层的 DenseNet 测试结果的混淆矩阵如上所述，与真实测试集准确率相对应。

4.3 循环神经网络（RNN）

4.3.1 模型超参数设置

表 10 RNN 超参数设置

超参数	数值
初始学习率 lr	0.0001
迭代次数 nepoches	250
动量 momentum	0.9

批次大小 batch_size	32
随机失活 dropout	0

RNN 模型统一的超参数设置如上表所述，优化器采用随机梯度下降（Stochastic Gradient Descent, SGD）。

4.3.2 模型结构

RNN 选取了四种模型：两层 GRUCell 的 GRU 网络和带首层 BN 层的两层 GRUCell 的 GRU 网络，两层 LSTMCell 的 LSTM 网络和两层 LSTMCell 的 LSTM 网络，四种模型都接上一层 BN 层，全连接层和 softmax 激活函数做分类器。

表 11 RNN 模型结构

模型名称	模型结构	详细信息
GRU	GRUCell	(96, 300)
	GRUCell	(300, 300)
	bn2	300
	fc1	(300, 12)
	softmax	—
GRU(with first BN layer)	bn1	96*96
	GRUCell	(96, 300)
	GRUCell	(300, 300)
	bn2	300
	fc1	(300, 12)
	softmax	—
LSTM	LSTMCell	(96, 300)
	LSTMCell	(300, 300)
	bn2	300
	fc1	(300, 12)
	softmax	—
LSTM(with first BN layer)	bn1	96*96
	LSTMCell	(96, 300)
	LSTMCell	(300, 300)
	bn2	300
	fc1	(300, 12)
	softmax	—

4.3.3 模型参数量统计

表 13 RNN 参数量统计

模型名称	FLOPS	Params
GRU	2777.86M	0.90M
LSTM	3701.30M	1.20M

两层 GRUCell 的 GRU 网络和两层 LSTMCell 的 LSTM 网络浮点计算次数和参数量如上所示。

4.3.4 Loss 曲线

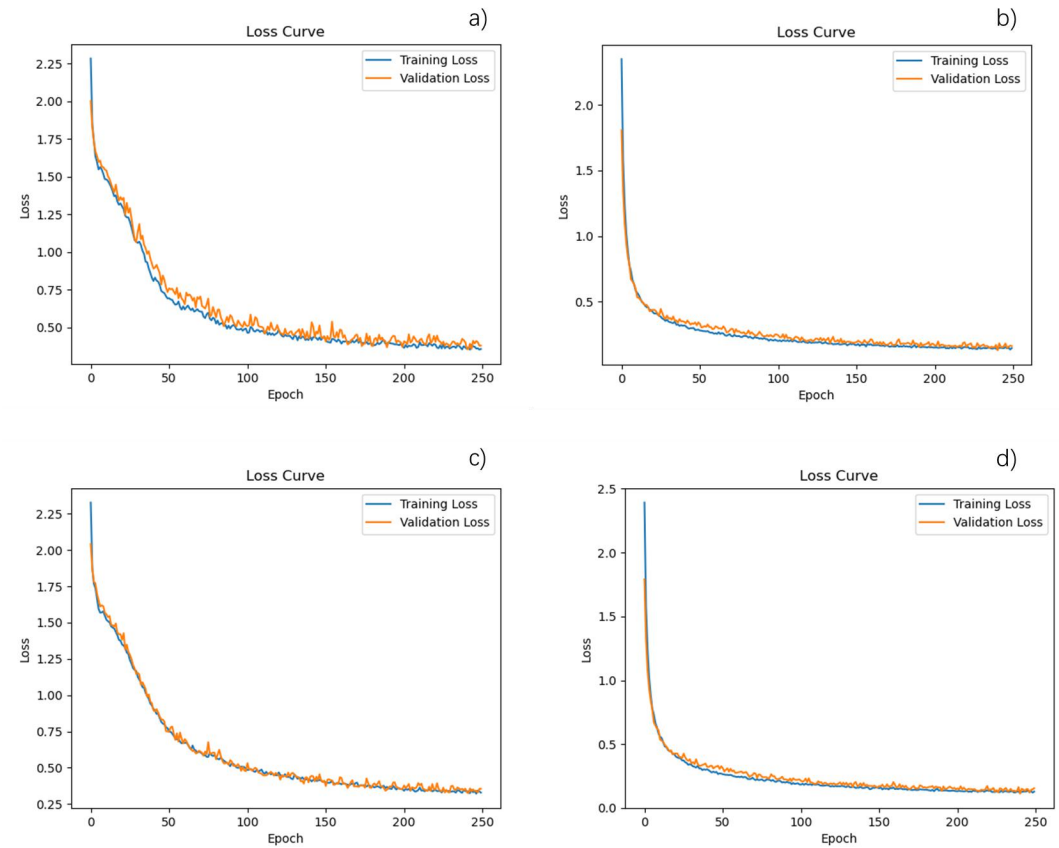


图 9 RNN 训练过程中训练和验证的 Loss 曲线 a)GRU b)GRU(BN) c)LSTM d)LSTM(BN)

两层 GRUCell 的 GRU 网络和带首层 BN 层的两层 GRUCell 的 GRU 网络，两层 LSTMCell 的 LSTM 网络和两层 LSTMCell 的 LSTM 网络的真实测试集准确率分别为 78.15%、95.80%、80.67%和 96.64%。训练的训练与验证的 Loss 曲线如上所述。

4.3.5 混淆矩阵

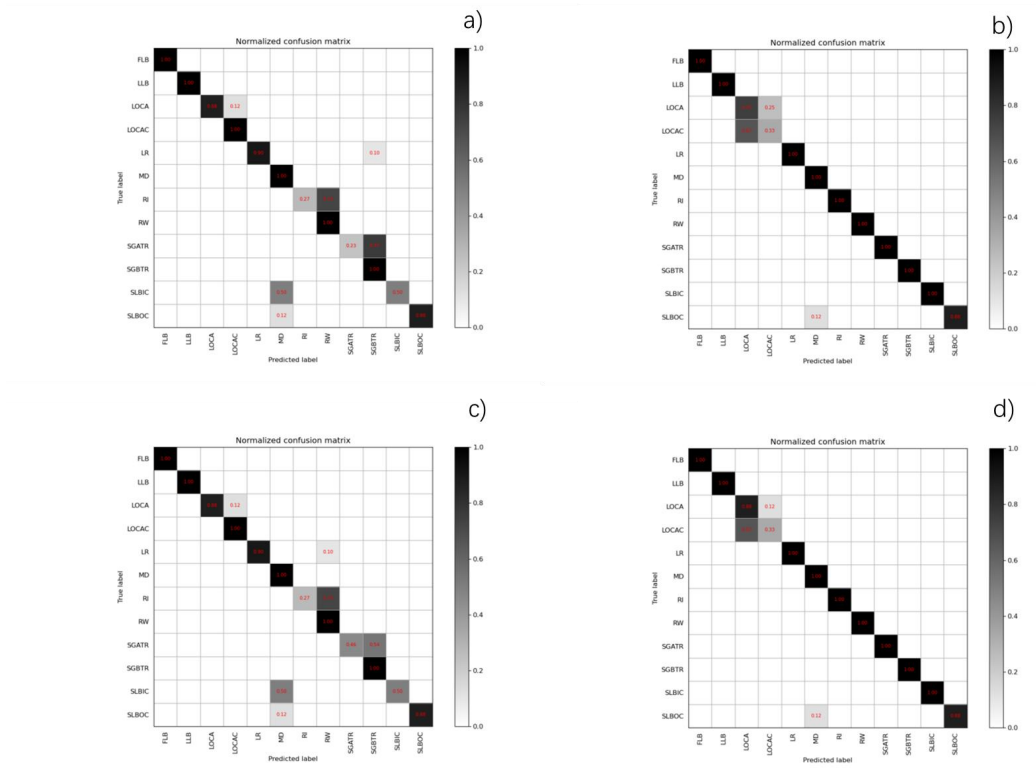


图 10 RNN 网络最佳模型的混淆矩阵 a)GRU b)GRU(BN) c)LSTM d)LSTM(BN)

两层 GRUCell 的 GRU 网络和带首层 BN 层的两层 GRUCell 的 GRU 网络，两层 LSTMCell 的 LSTM 网络和两层 LSTMCell 的 LSTM 网络的混淆矩阵如上所述，与真实测试集准确率相对应。

4.4. Transformer 网络

4.4.1 模型超参数设置

表 14 Transformer 超参数设置

超参数	数值
初始学习率 lr	0.001
迭代次数 nepoches	250
动量 momentum	0.9

批次大小 batch_size	32
随机失活 dropout	0

训练时优化器采用 SGD，参数如上表中所示。

4.4.2 模型结构

模型采用了由 Encoder 模块组成的 Transformer，最后加上全连接层和平均池化输出 12 个类别的概率。

表 15 Transformer 模型结构

模型名称	模型结构	详细信息
Transformer	Encoder Block1	d=96, nhead=2
	Encoder Block2	d=96, nhead=2
	FC	(96, 12)
	Average Pooling	(1, 12)
	softmax	—
Transformer(with first BN layer)	BN_1d	(9216)
	Encoder Block1	d=96, nhead=2
	Encoder Block2	d=96, nhead=2
	FC	(96, 12)
	Average Pooling	(1, 12)
	softmax	—

4.4.3 模型参数量统计

表 16 Transformer 参数量统计

模型名称	FLOPS	Params
Transformer	121.50M	0.04M

4.4.4 Loss 曲线

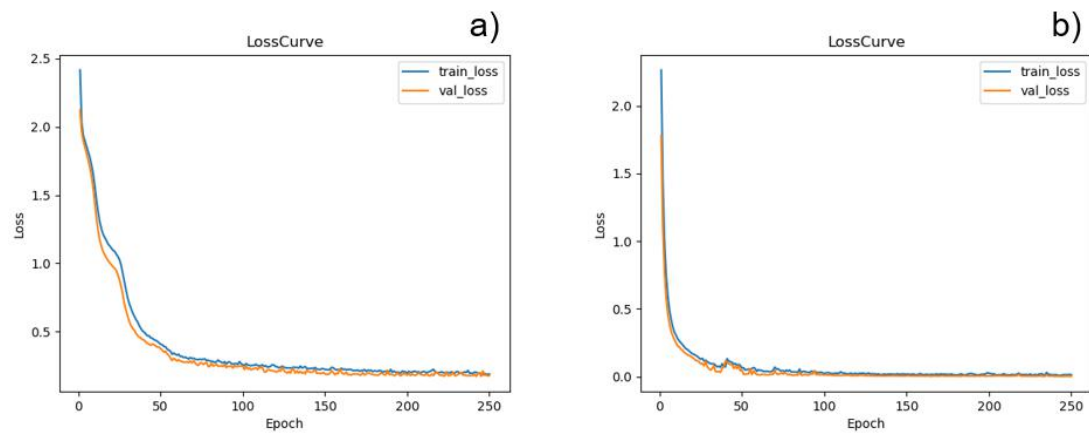


图 11 Transformer 训练过程中训练和验证的 Loss 曲线。 a)Transformer b)Transformer with BN

Transformer 和带首层 BN 层的 Transformer 在真实数据测试集上的准确率为 88.24% , 99.16%。

4.4.5 混淆矩阵

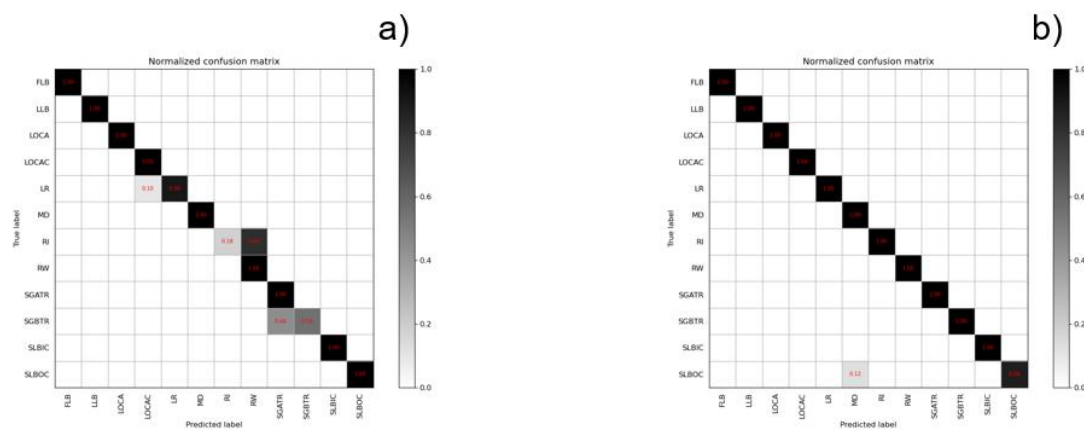


图 12 混淆矩阵 a) Transformer b) Transformer with BN

4.5 模型对比

4.5.1 模型超参数设置

表 17 各模型相同的超参数设置

超参数	数值
初始学习率 lr	0.001
迭代次数 nepoches	250
动量 momentum	0.9
批次大小 batch_size	32
随机失活 dropout	0

报告涉及的所有模型经过测试后，采用的相同的超参数如上表所述。测试结果表明对报告所使用的模型，训练使用的超参数都得到相对较好的训练模型。

4.5.2 模型信息和结果

报告涉及的所有模型的浮点数计算次数和参数量以及在真实数据划分的测试集准确率都在下表列出。其中所有模型的浮点数计算次数和参数量的数据可视化在下图：




图 18 模型浮点计算速度、参数量和测试集准确率三维图

模型浮点计算次数由小到大为：

MLP1<<Transformer<MLP4<<DenseNet_4<GRU<LSTM<<ResNet_3

参数量由小到大为：

Transformer<MLP1<DenseNet_4<ResNet_3<GRU<LSTM<MLP4

同类型的网络参数大小和浮点计算次数的相对大小具有一致性，但是对非同类型的网络而言，网络参数大小和浮点计算次数的相对大小没有一致性。因为单位参数对应的浮点计算数由小到大为：

MLP1~MLP4<<Transformer~LSTM~GRU<DenseNet_4<ResNet_3

MLP 的 FLOPs/Params 远小于 RNN，RNN 的 FLOPs/Params 约等于 Transformer 的 FLOPs/Params，远小于 CNN。

FLOPs/Params 反映了不同模型单位空间成本下所需要的时间成本。不同的模型具有相对统一的 FLOPs/Params。MLP 的全连接层属于线性模型，可以简单表达成 $WX+B$ ，没有批处理的时候一个待定参数只需要执行一次计算，由于报告选择的 batch 的大小为 32，所以 FLOPs/Params 约等于 32。

RNN 和 Transformer 相比于 MLP 在数据的处理过程中多出了时序处理部分，参数共享的情况下，单一待定参数需要的计算次数为 $\text{batch_size} \times \text{sequence length} = 32 \times 96 = 3072$ 。

CNN 涉及卷积的滚动乘积（与卷积核大小有关）和直连，情况较为复杂。但是可以确定的是单位参数对应的浮点计算一定程度上要大于 RNN 和 Transformer，远大于 MLP 网络。

表 18 模型测试结果汇总表

模型名称	FLOPs	Params	FLOPs/Params	测试集准确率
MLP1	3.54M	0.11M	32.18	67.23%
MLP1(with first BN layer)				99.16%
MLP4	155.84M	4.87M	32.00	62.18%
MLP4(with first BN layer)				99.16%
ResNet_3	12187.01M	0.50M	24372.02	67.23%
ResNet_3 (with first BN layer)				99.16%
DenseNet_4	1469.34M	0.19M	7733.37	38.66%
DenseNet_4 (with first BN layer)				99.16%
GRU	2777.86M	0.90M	3086.51	78.15%
GRU(with first BN layer)				95.80%
LSTM	3701.30M	1.20M	3084.42	80.67%
LSTM(with first BN layer)				96.64%

Transformer	121.50M	0.04M	3037.5	88.24%
Transformer(with first BN layer)				99.16%

4.5.3 分析与讨论

(1) 模型

对比几个模型的准确率， $MLP1(BN) = MLP4(BN) = ResNet_3(BN) = DenseNet_4(BN) = Transformer(BN) > LSTM(BN) > GRU(BN) > Transformer > LSTM > GRU > ResNet_3 > MLP1 > MLP4 > DenseNet_4$ 。在模型没有首层 BN 层时，效果最好的是 Transformer，其次是 RNN（LSTM 和 GRU），在这两类模型中我们均是把事故数据当做时间序列来处理，体现出数据的时序信息对判断事故类别起着比较重要的作用，其中 Transformer 不仅准确率最高，参数量和运算量也很小。CNN 的结果次于上述两类模型，在 CNN 中我们把每一例事故数据（96*96 大小）当做图像处理，但数据并不具有像自然图像那样的二维结构信息，因此效果一般。MLP 的准确率和它的隐藏层层数关系不大，模型变大，效果未必变好。另外，层数较少的 MLP 层加入非线性激活函数反而会降低模型的准确率，我们认为是 ReLU 函数在网络层数太少时会影响梯度的更新，我们用 Sigmoid 函数替代 ReLU 能在效果上获得不错的提升，直接去掉激活函数，效果还会进一步提升，我们认为原因在于数据里存在一些线性可分的特征，加入非线性激活函数，在隐藏层较少时会影响它们的线性可分性。

(2) 数据标准化

实验中我们发现，在模型前加上一个 BN 层后，模型的效果均会提升至 95% 以上，即使是一层 MLP 也可以非常准确地对事故进行分类，我们认为该 BN 层的作用与数据预处理时进行标准化（减均值、除以方差）的作用类似，差别仅在于 BN 层在训练时使用的是该 batch 的均值与标准差，而数据标准化使用的是全体数据的均值与标准差，并且 BN 层含有两个可学习参数（scale 参数 γ 和 shift 参数 β ）。输出训练好的模型 BN 层的 γ 和 β ，我们发现 $\gamma \approx 1$ ， $\beta \approx 0$ ，因此可以认为该 BN 层的作用和数据标准化近似相同。我们进行了实验验证，去掉了模型的首层 BN 层，并在数据预处理中加入标准化操作，发现最终准确率也均在 95% 以上，验证了我们的想法。

在一开始我们只将数据集作了归一化处理，效果跟后来做了标准化处理相比相差较多，我们认为原因在于事故数据中的异常值较多、偏离均值较远，造成归一化的效果不佳，而标准化能避免这一问题，更好的保持样本间距。

(3) 混淆矩阵

根据各个模型结果的混淆矩阵，可以看出 FLB、RW 属于比较容易判断出的类别，在所

有的模型中都能较准确地识别出来，而 SLBOC 和 MD 容易混淆，在几乎大部分模型中 SLBOC 都有一部分数据容易被误判为 MD。除了 SLBOC 和 MD 之外，其他大部分类别的数据在模型做了标准化预处理之后都能被较好地分类。

5.项目总结

5.1 结论

本项目开展了核电厂事故数据集构建、虚假数据集生成和事故分类等工作，初步验证了深度学习模型—多层感知机（MLP）、卷积神经网络（CNN）、循环神经网络（RNN）、Transformer 和 GAN 等网络在核电厂事故诊断领域应用的可行性。实验结果表明：

- （1）数据集大小和数据预处理方法对深度学习模型的结果有较大影响。
- （2）生成虚假数据集方面，TimeGAN 相较于 cGAN 表现出更高的性能，TimeGAN 可以更好的捕捉时序数据的动态特征。
- （3）事故诊断方面，我们基于 MLP、CNN、RNN、Transformer 四类模型对事故类别进行分类，在真实数据上进行实验，结果表明 Transformer 对事故有最好的分类能力。另外，在数据预处理时进行标准化处理，会使得所有模型的效果都大幅度提高。

5.2 展望

- （1）初始阶段针对数据集做详细数据分析，将有助于选取更合适的深度学习模型。
- （2）未来工作将进一步探索深度学习模型在时序数据异常监测和关键参数预测方面的应用。

参考文献

- [1] Qi, B., Xiao, X., Liang, J. et al. An open time-series simulated dataset covering various accidents for nuclear power plants. Sci Data 9, 766 (2022). <https://doi.org/10.1038/s41597-022-01879-1>.
- [2] Mirza M , Osindero S . Conditional Generative Adversarial Nets:, 10.48550/arXiv.1411.1784[P]. 2014.Yoon J, Jarrett D, Van der Schaar M.
- [3] Time-series generative adversarial networks[J]. Advances in neural information processing systems, 2019, 32.